




主成分分析PCA并给出解释百分比



邓飞


+ 关注他

18 人赞同了该文章

大家好，我是邓飞，有时候我们做PCA图，图很漂亮，我们解释一通，充满自信。但是，你知道这个图解释变异的百分比吗？如果解释度很低，那也意义不大。这我们就需要在PCA图中，将PC1和PC2的解释百分比附上面，比如PC1解释8%的变异，PC2解释4%的变异，那么这个PCA图可以解释12%的变异。

问题来了：如何计算PC1和PC2的解释百分比？如何放到图中？

教程来了！目标图（如下图）：包括PC1和PC2的散点图，以及PC1和PC2的解释百分比。



1. 处理思路

「思路：」

- 1, 根据plink文件，进行pca分析
- 2, 根据特征值，计算pca1和pca2的解释百分比

3, 根据特征向量+结果, 进行pca作图

2. 注意事项

「注意:」

特征值就是特征向量在对应维度的方差, 特征值所占所有特征值之和的比值, 就是其对应特征向量的方差贡献率。

简单来说:

- PCA1是特征向量, 其方差是PC1的特征值, 其方差贡献率为PC1特征值的百分比
- PCA2是特征向量, 其方差是PC2的特征值, 其方差贡献率为PC2特征值的百分比

3. 示例演示

「示例:」比如计算一个plink进行文件的3个pca, 结果如下:

```
plink--bfilegeno/b--pca3
```

结果包括:

- plink.eigenval, 特征值, 共有3行数据, 分别是3个PCA的特征值
- plink.eigenvec, 特征向量, 第三四五列是3个PCA的特征向量, 作图用前两个PCA

```
$headplink.eigenvec
0ID1-0.0320.01854070.0351135
0ID2-0.03306650.02130820.0575101
0ID3-0.03400430.0209365-0.00264537
0ID4-0.03236210.02039620.0503156
0ID5-0.03250160.01911830.0426273
0ID6-0.03467650.0196053-0.0408817

$headplink.eigenval
145.367
74.7594
6.10604
```

4. 计算PCA百分比

如果想要十分精确的计算每个PCA的得分, 那我们需要计算所有PCA的值, PCA的个数等于样本的个数。

比如我们的样本有575个, 那么它计算PCA的代码为:

```
plink--bfilegeno/b--pca575
```

可以看到, 样本数和pca的行数都是575行

```
$wc-lgeno/b.fam
575geno/b.fam
$wc-lplink.eigenvec
575plink.eigenvec
$wc-lplink.eigenval
575plink.eigenval
```


在R语言中计算每个PCA的百分比，以及PCA可视化：

```
library(tidyverse)
library(tidyverse)
re1a=fread("plink.eigenval")
re1b=fread("plink.eigenvec")

re1a$por=re1a$V1/sum(re1a$V1)*100
head(re1a)

ggplot(re1b,aes(x=V3,y=V4))+geom_point()+
xlab(paste0("PC1(",round(re1a$por[1],2),"%")")+
ylab(paste0("PC2(",round(re1a$por[2],2),"%")"))
```

结果：



5. 使用前10个做PCA百分比计算

因为PCA的特征向量从大到小排列，所以，也可以用前3个或者前10个作为代表，计算PC1和PC2的百分比，我们测试一下：

「取前三个」这个偏差太大了，PC1从原来的21%，到现在的64%，不靠谱！

```
> library(data.table)
> re1a = fread("plink.eigenval")[1:3,]
> re1b = fread("plink.eigenvec")
> re1a$por = re1a$V1/sum(re1a$V1)*100
> head(re1a)
      V1      por
1: 145.36700 64.255595
2:  74.75940 33.045393
3:   6.10604  2.699012
```

「取前十个」也不靠谱，变化也比较大，还是老老实实的用所有的特征值去计算百分比吧，麻雀虽

小，积土成山呀！

```
> # 前十个
> library(tidyverse)
> library(data.table)
> re1a = fread("plink.eigenval")[1:10,]
> re1b = fread("plink.eigenvec")
> re1a$por = re1a$V1/sum(re1a$V1)*100
> head(re1a)
```

	V1	por
1:	145.36700	55.584250
2:	74.75940	28.585891
3:	6.10604	2.334778
4:	5.70781	2.182506
5:	5.45088	2.084263
6:	5.22130	1.996478

「取所有」这个才是最正确的！

```
> re1a = fread("plink.eigenval")[1:575,]
> re1b = fread("plink.eigenvec")
> re1a$por = re1a$V1/sum(re1a$V1)*100
> head(re1a)
```

	V1	por
1:	145.36700	21.4760229
2:	74.75940	11.0446978
3:	6.10604	0.9020854
4:	5.70781	0.8432523
5:	5.45088	0.8052944
6:	5.22130	0.7713770

6. 一步到位

现在的问题是，样本的个数，还要查看，然后定义--pca number，再读取，可以在R中一步到位：

思路：

- 读取plink文件的fam，确定个数
- R中调用plink，传参个数
- 作图

```
args="geno/b"
nn=dim(fread(paste0(args[1], ".fam"), header=F))[1]
system(sprintf("~/bin/plink--bfile%s--allow-extra-chr--chr-set30--pca%s", args[1], nn))
re1a=fread("plink.eigenval")
re1b=fread("plink.eigenvec")
```

```
re1a$por=re1a$V1/sum(re1a$V1)*100
head(re1a)

ggplot(re1b,aes(x=V3,y=V4))+geom_point()+
xlab(paste0("PC1(",round(re1a$por[1],2),"%")"))+
ylab(paste0("PC2(",round(re1a$por[2],2),"%")"))
```

相关阅读:

[GWAS分析+从开始到放弃](#)

[育种中PCA分析可视化](#)

[基因型数据绘制PCA图和聚类分析图](#)

编辑于 2023-01-12 03:51 · IP 属地新加坡

- 学习分析learning analytics
- 经济分析
- 分析统计



理性发言，友善互动

4 条评论

默认 最新



小杰杰呀

请问两者之和为100%是什么原因呢，数据能用吗

2023-09-23 · 天津

回复 喜欢



wanna

博主你好 我想问下如何看PCA3呢 R语言中有什么代码可以看的吗 因为在图中只能看到PCA1和PCA2

2023-03-28 · 广西

回复 喜欢



wanna · 人机

好的好的 谢谢~

2023-07-20 · 广西

回复 喜欢



人机

pcoa = dudi.pco(bray_dist,scannf = F,nf=2)，用这串代码计算pcoa就行了，nf=3就会显示pca3

2023-05-29 · 新加坡

回复 喜欢

推荐阅读

如何看懂主成分分析PCA图

当我们拿到很多类型的报告的时候，其中可能都会包括一张PCA图，一张二维坐标或者三维坐标散点图，其中的点或聚集或分散，可能还标上了不同的颜色，看起来简直就像是夜空中最闪亮的焰火，初...

联川生物



什么是PCA，简单通俗的理解及应用

Chinmeya

PCA主成分分析实战和可视化 | 附R代码和测试数据

一文看懂PCA主成分分析中介绍了PCA分析的原理和分析的意义(基本简介如下，更多见博客)，今天就用数据来实际操练一下。（注意：用了这么多年的PCA可视化竟然是错的!!!）在公众号后台回复...

生信宝典 ...

发表于生信宝典



关于主成分分析(PCA)几个核心问题

梁子

发于

▲ 赞同 18

▼

● 4 条评论

🔗 分享

♥ 喜欢

★ 收藏

📄 申请转载

...

